ОНОМАСТИЧЕСКАЯ СПЕЦИФИКА РОМАНА Е. ЗАМЯТИНА «МЫ» В КОНТЕКСТЕ ФАНТАСТИЧЕСКОГО И АНТИУТОПИЧЕСКОГО ДИСКУРСА ОТЕЧЕСТВЕННОЙ ЛИТЕРАТУРЫ 1920-Х ГОДОВ

Проект № 1

Студеникина Д. Г.

Какой интерес представляют онимы в данном жанре литературы?

Создание мира – онимы именуют реалии антиутопии, формируя её образность (номинация несуществующих референтов)

Отражение языковой личности автора – передают языковое своеобразие, психолингвистические и социокультурные черты ЯЛ автора

Оним – имя собственное

Специфика онимов

Цель проекта:

обнаружить связь жанровой специфики и особенностей языковой личности автора с формированием онимов

Задачи:

Сравнить **относительную частотность онимов из романа «Мы»:**

1. В фантастических/антиутопических произведениях 1920–х гг.
2. В тексте романе «Мы» Е. Замятина

Социокультурный контекст *Психолингвистическое (уникальность)*

Источники

- Беляев А. Борьба в эфире 1927
- Беляев А. Властелин мира 1926
- Беляев А. Голова профессора Доуэля 1925
- Грин А. Блистающий мир 1923
- Замятин Е. Мы 1924
- Олеша Ю. Три толстяка 1924
- Платонов А. Чевенгур 1927
- Платонов А. Котлован 1930
- Толстой А. Гиперболоид инженера Гарина 1927

Корпус 1

Этап 1

Работа с большим корпусом (9 произведений, включая "Мы")

Импортированы:

os, re, nltk, Counter, stopwords, pandas, word_tokenize, MorphAnalyzer

Установлена pymorphy3,

Токенизация, приведение к нижнему регистру, удаление пунктации, удаление стоп-слов, лемматизация, проверка частей речи

Убраны служебные части речи и пунктуация

```python
# из-за новизны и уникальности авторской ономастики многие слова (онимы) не маркируются верно. Поэтому придется оставить все знаменательные части речи
no_parsorat_tokens = []
for lemma in list_tokens[:50]:
    parsed = morph.parse(lemma)[0]
    if parsed.tag.POS not in {'CONJ', 'PRCL', 'INTJ', 'PNCT'}:  # убираем служебные части речи, пунктуацию
        no_parsorat_tokens.append(lemma)

print(no_parsorat_tokens)
```

✓ 0.1s Python

```
['глава', 'первый', 'летний', 'вечер', 'сидеть', 'садовый', 'окрасить', 'зелёный', 'цвет', 'плетёный', 'кресло', 'край', 'широкий', 'аллея', 'каштановый', 'цвету
```

591957 → 288871

Как маркируются имена

- **эа: UNKN**

- **д503: UNKN**
- **о90: UNKN**
- **ю: UNKN**
- **i330: LATN**
- **i: ROMN**

хлынов: ADJS,Qual masc,sing

мочь: NOUN,inan,femn sing,nomn

Подсчет абсолютной и относительной частоты в корпусе1

	A	B	C
1	слово	абсолютная частота	относительная частота
2	голова	586	0.008358294109256882
3	сказать	537	0.007659392383397518
4	свой	507	0.007231493367565255
5	эльза	491	0.007003280559121381
6	штирнер	438	0.006247325631151049
7	керн	428	0.006104692625873627
8	который	399	0.005691056910569106
9	мочь	375	0.005348737697903295
10	человек	363	0.00517757809157039
11	лоран	359	0.005120524889459421
12	рука	353	0.005034945086292968
13	зауер	322	0.004592782769932962
14	наш	315	0.004492939666238768
15	брик	299	0.004264726857794894
16	говорить	290	0.004136357153045215
17	ваш	262	0.003736984738268435
18	готлиб	260	0.003708458137212951
19	знать	242	0.003451718727713593

Корпус 2

Этап 2

Работа с корпусом 2 (текст романа «Мы»)

Токенизация, приведение к нижнему регистру, удаление пунктации, удаление стоп-слов, лемматизация, удаление служебных частей речи

Подсчет абсолютной и относительной частоты токенов в корпусе2 и корпусе1

1	слово	абсолютная частота	относительная частота	частота_по_corpus1
2	знать	207	0.00848013109381401	0.002952503209242619
3	рука	206	0.008439164276935682	0.002938239908714877
4	глаз	189	0.007742728390004097	0.0026957637997432607
5	стена	129	0.005284719377304383	0.0018399657680787335
6	весь	123	0.005038918476034412	0.0017543859649122807
7	видеть	121	0.004956984842277755	0.0017258593638567964
8	мочь	117	0.00479311757476444	0.001668806161745828
9	древний	115	0.004711183941007784	0.0016402795606903437
10	сказать	107	0.004383449405981155	0.0015261731564684068
11	і	105	0.0043015157722244984	0.0014976465554129225
12	голова	100	0.004096681687832855	0.001426330052774212
13	свой	95	0.0038918476034412127	0.0013550135501355014
14	лицо	94	0.003850880786562884	0.0013407502496077593
15	день	89	0.0036460467021712413	0.0012694337469690486
16	наш	88	0.003605079885292913	0.0012551704464413066
17	говорить	87	0.003564113068414584	0.0012409071459135643
18	ясно	87	0.003564113068414584	0.0012409071459135643
19	хотеть	86	0.003523146251536256	0.0012266438453858222
20	дверь	86	0.003523146251536256	0.0012266438453858222
21	понимать	81	0.0033183121671446127	0.0011553273427471118
22	самый	78	0.0031954117165096272	0.0011125374411638854
23	должный	75	0.0030725112658746417	0.001069747539580659

Сбор онимов из текста «Мы»

Этап 3

Обработка онимов (нижний регистр, лемматизация), подсчет частототности относительно корпуса1 и корпуса2

Частотность онимов в корпусе2 и корпусе1

1	слово	отная ч	частота_по_corpus2	частота_по_corpus1
2	кант	1	4.096681687832855e-05	1.4263300527742119e-05
3	скрябин	1	4.096681687832855e-05	1.4263300527742119e-05
4	тэйлор	1	4.096681687832855e-05	1.4263300527742119e-05
5	маклорен	1	4.096681687832855e-05	1.4263300527742119e-05
6	будда	1	4.096681687832855e-05	1.4263300527742119e-05
7	пушкин	1	4.096681687832855e-05	1.4263300527742119e-05
8	шекспир	1	4.096681687832855e-05	1.4263300527742119e-05
9	достоевский	1	4.096681687832855e-05	1.4263300527742119e-05
10	колумб	1	4.096681687832855e-05	1.4263300527742119e-05
11	галилей	1	4.096681687832855e-05	1.4263300527742119e-05
12	иегова	1	4.096681687832855e-05	1.4263300527742119e-05
13	иисус	1	4.096681687832855e-05	1.4263300527742119e-05
14	навина	1	4.096681687832855e-05	1.4263300527742119e-05
15	европеец	1	4.096681687832855e-05	1.4263300527742119e-05
16	дикарь	1	4.096681687832855e-05	1.4263300527742119e-05
17	америка	1	4.096681687832855e-05	1.4263300527742119e-05
18	эльдорадо	1	4.096681687832855e-05	1.4263300527742119e-05
19	атлантида	1	4.096681687832855e-05	1.4263300527742119e-05
20	космонимый	1	4.096681687832855e-05	1.4263300527742119e-05
21	луна	1	4.096681687832855e-05	1.4263300527742119e-05
22	венера	1	4.096681687832855e-05	1.4263300527742119e-05
23	марс	1	4.096681687832855e-05	1.4263300527742119e-05

Извлечь именованные сущности

Проверить, насколько точно можно собрать имена из текста такого рода (Natasha)

Сравнение длин онимов (собранных «вручную» и кодом)

```
len(onims_my)
[49] ✓ 0.0s
145
```

```
len(lemmatized_all_names)
[51] ✓ 0.0s
118
```

	A	B
1	онимы1	онимы_от_наташи
2	кант	благодетель
3	скрябин	кончить
4	тэйлор	направо
5	маклорен	о...
6	будда	о.
7	пушкин	материнская норм
8	шекспир	благодетель
9	достоевский	зеленой стена
10	колумб	скрижаль
11	галилей	часовая скрижаль
12	иегова	скрижаль
13	иисус	кант
14	навина	материнский
15	европеец	отцовской норма
16	дикарь	о
17	америка	скрябин
18	эльдорадо	тэйлор
19	атлантида	маклорена
20	космонимый	пифагоров
21	луна	о. ть
22	венера	хранитель
23	марс	о. протянуть
24	меркурий	конспект

Разбиение на компоненты при токенизации

вручную

материнский
норма

кодом

материнская норм

Проблемы сбора кодом

Код собирал не только именованные сущности (даже не именные части речи)

кончить
направо
о. протянуть
о. штора
по-нима-ть
щёлк

Частотность ИС от natasha в корпусе 2 и корпусе 1

1	слово	отная ч	частота_по_corpus2	частота_по_corpus1
2	благодетель	4	0.0001638672675133142	5.7053202110968475e-05
3	кончить	1	4.096681687832855e-05	1.4263300527742119e-05
4	направо	1	4.096681687832855e-05	1.4263300527742119e-05
5	о...	1	4.096681687832855e-05	1.4263300527742119e-05
6	о.	1	4.096681687832855e-05	1.4263300527742119e-05
7	материнская норм	1	4.096681687832855e-05	1.4263300527742119e-05
8	зеленой стена	1	4.096681687832855e-05	1.4263300527742119e-05
9	скрижаль	2	8.19336337566571e-05	2.8526601055484238e-05
10	часовая скрижаль	1	4.096681687832855e-05	1.4263300527742119e-05
11	кант	1	4.096681687832855e-05	1.4263300527742119e-05
12	материнский	1	4.096681687832855e-05	1.4263300527742119e-05
13	отцовской норма	1	4.096681687832855e-05	1.4263300527742119e-05
14	о	1	4.096681687832855e-05	1.4263300527742119e-05
15	скрябин	1	4.096681687832855e-05	1.4263300527742119e-05
16	тэйлор	3	0.00012290045063498566	4.2789901583226356e-05
17	маклорена	1	4.096681687832855e-05	1.4263300527742119e-05
18	пифагоров	1	4.096681687832855e-05	1.4263300527742119e-05
19	о. ть	1	4.096681687832855e-05	1.4263300527742119e-05
20	хранитель	3	0.00012290045063498566	4.2789901583226356e-05
21	о. протянуть	1	4.096681687832855e-05	1.4263300527742119e-05
22	конспект	1	4.096681687832855e-05	1.4263300527742119e-05
23	ньютон	1	4.096681687832855e-05	1.4263300527742119e-05

Визуализация

matplotlib.pyplot

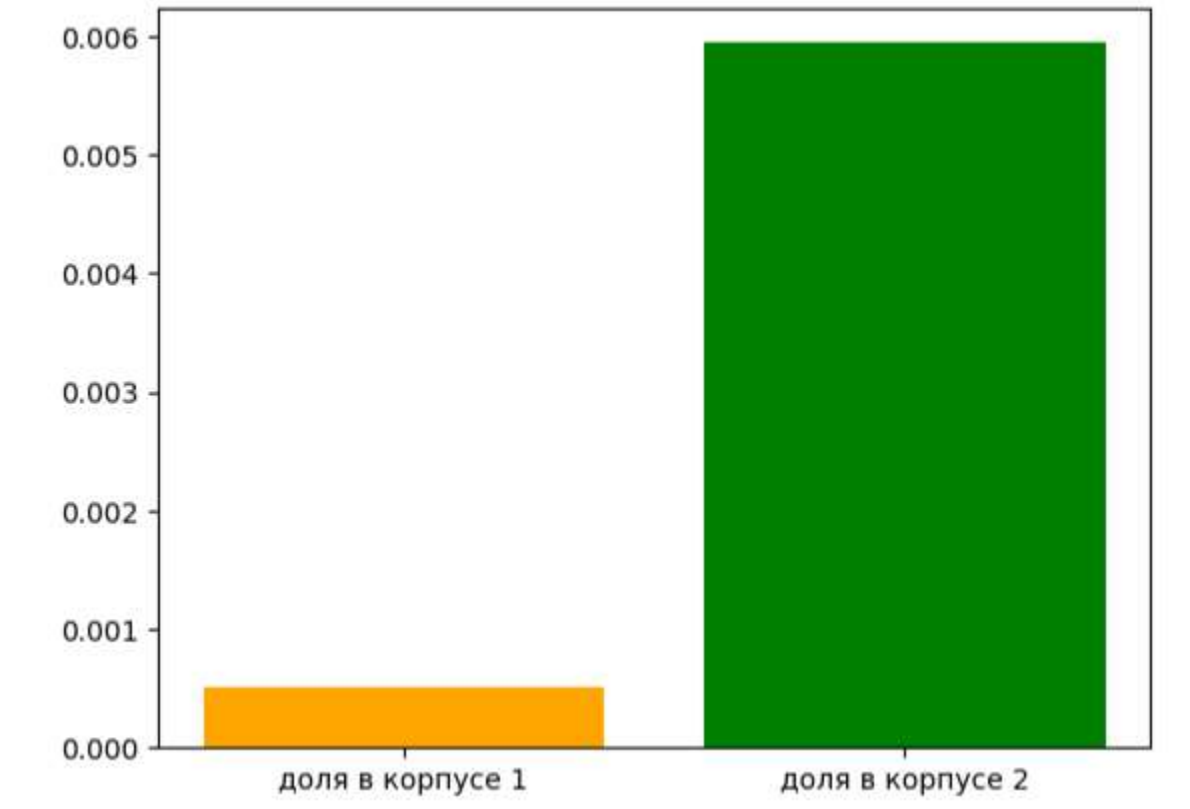

Онимы

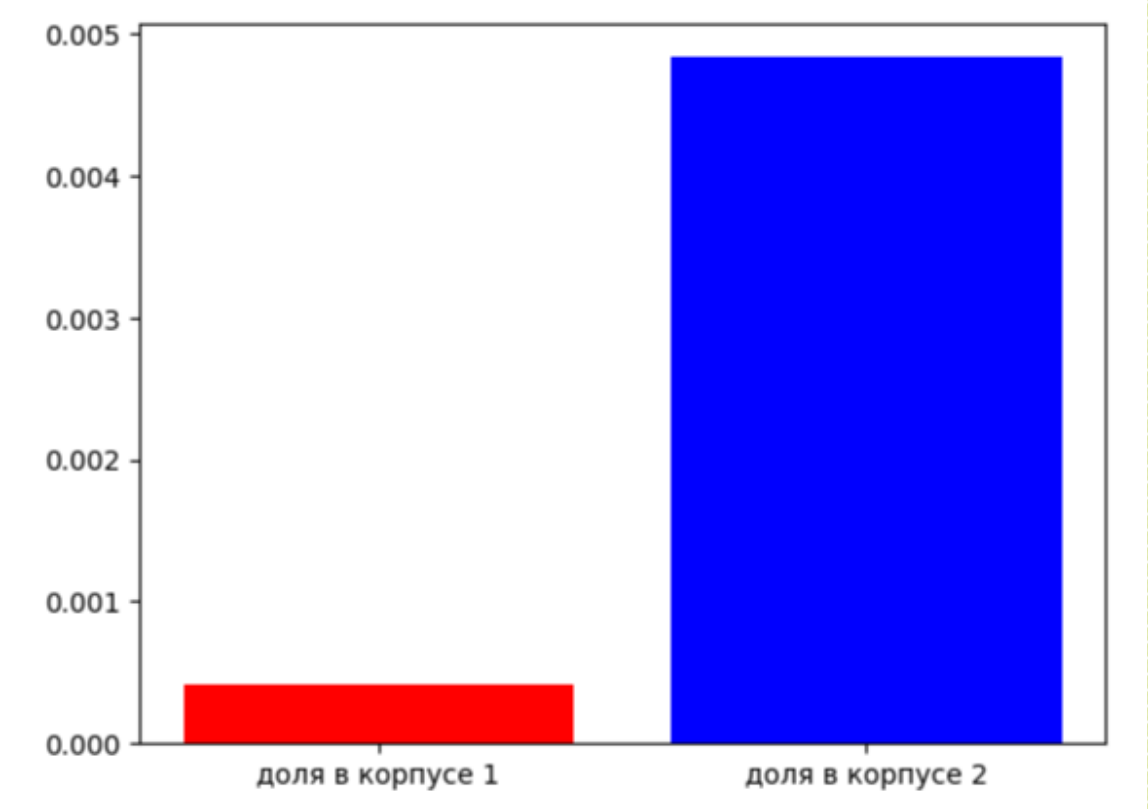

Natasha

Выводы

Онимы в тексте «Мы» специфичны (доля этой лексики в корпусах)

Авторские онимы невозможно адекватно определить с помощью инструмента для извлечения именованных сущностей

Спасибо за внимание